

Sistemas Distribuidos I
(75.74)

Wikipedia Article Analysis

TP Esalabilidad

Requerimientos Funcionales

- Se solicita un sistema distribuido que analice un conjunto de artículos obtenidos de Wikipedia en los idiomas Francés e Inglés.
- Se debe obtener:
  1. Url y fecha de modificación para artículos escritos en inglés hasta 2020 inclusive.
  2. Nombre, url e imágen (bytes) de artículos escritos hasta 2020 inclusive que incluyan “biography” o “biographie” entre sus secciones.
  3. Listado de palabras únicas compartidas entre cualquier artículo escrito en inglés y cualquier artículo escrito en francés.
  4. Pares (palabra, cantidad) del top 20 palabras más utilizadas entre todos los abstracts. Dentro de un mismo abstract las palabras se cuentan una sola vez y las palabras triviales (stopwords) se excluyen del top.
  5. Url y cantidad de palabras de abstract para los artículos escritos a partir del 2021 cuya cantidad de palabras en el abstract sea superior al promedio de palabras de abstract de todos los artículos escritos hasta el 2020 inclusive. Se aplica el mismo criterio para contabilizar palabras que la query anterior.

Requerimientos Funcionales



- Respecto a la ejecución de los clientes se espera:
  - Una ejecución por cliente. Si el cliente se reinicia y se conecta sin que se haya reiniciado el servidor se podrá atender como uno nuevo. No es necesario permitir más de una única ejecución por cliente.
  - Ejecución aislada y concurrente entre varios clientes.
  - Eventual limpieza de los recursos.
- Aún se asume que no existen fallas de los clientes o el servidor.

Requerimientos No Funcionales



- El sistema debe estar optimizado para entornos multicomputadoras. Se debe soportar el incremento de los elementos de cómputo para escalar respecto a la cantidad de clientes atendidos y al volúmen de información a procesar por cliente.
- Se requiere del desarrollo de un Middleware para abstraer la comunicación basada en grupos.
- Se debe garantizar *graceful quit* frente a señales SIGTERM.

Datasets, notebook patrón y librerías



- Se trabajará sobre los datos de un dataset de Kaggle.
- Para la descarga de las imágenes se recomienda el uso de la API de Wikimedia.
- Se provee un notebook de referencia para guiar la interpretación del enunciado. No obstante, debido a la naturaleza abierta del problema se espera que los requerimientos se perfeccionen con el docente asignado a lo largo del tiempo.

Normas de Trabajo

Se espera del alumno:

- Empleo del tiempo de consultas en clase para resolver dudas y clarificar el negocio del sistema a construir previo a su diseño.
- Exposición y verificación en clase de la arquitectura propuesta antes de iniciar su implementación.
- Empleo del grupo de correos para realizar consultas que no pudieran ser resueltas en clase.
- Consideración de prácticas distribuidas según lo estudiado en clase para elaborar una arquitectura flexible, escalable y robusta.
- Aprobación del cuerpo docente para el uso de cualquier biblioteca.
- Demo del sistema en funcionamiento previamente ensayada.
- Recordar leer los criterios de corrección.

Entrega

- Formato de entrega:
  - Demo del sistema funcionando con una muestra significativa del dataset.
  - Entrega por campus de enlace al último commit del repositorio del trabajo.
  - Documento de arquitectura **actualizado** INFORME.md o INFORME.pdf en la raíz del repositorio. De tipo 4+1 Views o C4Model incluyendo al menos: diagramas de robustez, despliegue, actividades, paquetes, secuencia y DAG.
  - **No se evaluará código.**